

신현수

1%의 정확도 향상과 1ms의 지연 시간 단축에 집착하는 AI 엔지니어

전화번호 010-4142-0654

GitHub [URL](#)

이메일 shyunsu3@gmail.com



자기소개

가설-지표-평가의 개선 플라이휠을 돌리며 한계 성능을 쥐어짜는 과정에 희열을 느끼는 엔지니어 신현수입니다. Advanced RAG 파이프라인(Bidcoin)에서는 LLM-as-Judge 평가를 11회 반복하며 답변 정확도를 0.52에서 0.78로 끌어올렸고, 생성형 AI 서비스(Go Gachi)에서는 프로덕션 실측 로그를 근거로 아키텍처를 개선해 응답 페이로드를 99.97% 줄였습니다. 청킹 사이즈와 프롬프트를 수십 번 미세조정하며 성능과 속도의 스위트팟을 찾는 이 집착은, 4년간 육군 특수임무대 팀장으로서 돌발 상황을 통제하고 대응 매뉴얼을 고쳐 쓰며 몸에 익힌 리스크 관리 경험에서 비롯됐습니다. 실서비스의 방대한 데이터에서 발생하는 할루시네이션과 성능 저하 문제를 끝까지 추적해 해결하는 AI 엔지니어가 되겠습니다.

경력

20.06.01 - 24.05.31	육군 군사경찰 / 하사 특수임무대 팀장
	- 예측 불가능한 전술 상황에서 발생할 수 있는 휴먼 에러와 대응 지연 요소를 제거하고, 팀 단위의 일관되고 신뢰성 높은 대응력 확보 - 과거 작전 실패/지연 사례를 분석하고, 상황별 대응 프로세스 설계 및 표준 매뉴얼(SOP) 수립 주도 - 비정형적인 위기 상황을 데이터 기반의 구조화된 시나리오로 변환하고, 출동 소요 시간을 기존 10분에서 5분으로 단축하며 최적의 작전 효율 달성

스킬

[LLM & RAG]

- Tech: OpenAI API, FAISS, BM25, Cross-Encoder, Self-RAG, RRF

[AI Serving & Backend]

- Tech: Python, FastAPI, Celery, Redis, PostgreSQL, Docker, GitHub Actions, Playwright, GCP, R2

[Frontend]

- Tech: Next.js, React, TypeScript, Tailwind CSS

[Core ML & Data Pipeline]

- Tech: PyTorch, YOLOv11, OpenCV, Copy-Paste, Optuna

프로젝트

AIM

| 배포 후 웹서비스 품질 변화를 진단하는 AI 모니터링 플랫폼

역할: 1인 풀사이클 개발·운영 (기획-개발-배포-운영)

기술: Python, FastAPI, Celery, Redis, Playwright, PostgreSQL, Next.js, Docker, GCP

저장소: [URL](#) 배포: [URL](#) 

- 점수·등급과 장애 판정은 결정론적 코드로 계산하고, LLM(Claude API)은 수집된 근거를 서술하는 역할로 제한해 판정 결과의 재현성 확보
- LLM 호출 실패 시 규칙 기반 리포트로 자동 전환하는 폴백 경로를 구현해 외부 API 장애에도 리포트 생성 보장
- 가용성·웹 성능·핵심 사용자 흐름을 한 번에 검사하는 Celery·Redis 비동기 파이프라인을 구축하고, 작업 완료 순서와 무관하게 점수·회귀 비교·리포트가 일관되게 수렴하도록 정합성 설계
- 일일 오프박스 백업과 복원 리허설로 검증한 복구 런북을 갖추고, 이를 기반으로 운영 중인 서비스의 GCP→Oracle Cloud 이전을 수행해 백업·복원 경로를 실전 재검증

Go Gachi

| 생성형 AI 기반 광고 이미지 자동 생성 서비스 MVP

역할: Team Leader & AI Pipeline Engineer / 5인 팀

기술: Python, FastAPI, OpenAI API, GCP, Docker, R2

저장소: [URL](#) 

- 프로덕션 요청 199건의 구간별 타이밍 실측(평균 62~79초, 최대 241초)을 근거로 비동기 Job 아키텍처를 도입, 최대 4분의 AI 추론을 UI 블로킹 없이 처리
- 이미지 생성 응답의 base64 인라인(평균 2.1MB 실측)을 R2 저장 URL 참조로 전환해 응답 페이로드 99.97% 감소(2.1MB → 0.5KB), 폴링 최적화로 상태 조회 트래픽 40% 이상 감소
- 55초 이상 병목이던 '로고 합성 기능'의 MVP 제외 결단과 텍스트 모델 경량화(gpt-5.4-mini) 전환으로 생성 비용·지연 동시 절감

Bidcoin

| 공공조달 RFP 문서 검색 품질 향상을 위한 Advanced RAG 파이프라인 구축

역할: RAG Integration & Model Optimization Lead / 5인 팀

기술: OpenAI API(GPT-4o), FAISS, BM25(Kiwi), Cross-Encoder(bge-reranker-v2-m3), Self-RAG, RRF

저장소: [URL](#) 

- 검색·생성 파트를 End-to-End로 통합하는 RAG 파이프라인을 설계하고, Cross-Encoder(bge-reranker-v2-m3) 재정렬과 Self-RAG 검증 단계를 직접 구현
- LLM-as-Judge 평가(RAGAS 호환 6지표 × 47문항)를 11회 반복하며 답변 정확도 0.52→0.78(+50%), 검색 재현율 0.51→0.76(+49%) 달성 (평가셋 기준 환각 0건, faithfulness 평균 0.97)
- HyDE 제거·Self-RAG 프리패스·검색 병렬화와 FAISS/Chroma A/B 벤치마크(1.8배 빠른 구성 채택)로 질의당 LLM 호출 2회 절감, 응답 지연 1~2초 단축 — 품질 지표 하락 없음

객체 인식 모델	경구약(알약) 이미지 객체 탐지 모델 개발
	역할: Model Architect & Experimentation Lead / 5인 팀
	기술: Python, PyTorch, YOLOv8, OpenCV, Optuna
	저장소: URL 
	• Kaggle Public 리더보드 mAP@[0.75:0.95] 0.956, 추론 57ms/장(GTX 1650 SUPER 실측)으로 서비스 적용 가능한 정확도·속도 확인 • 실험 로그와 성능 평가 지표를 문서화해 팀 단위의 재현 가능한 실험 환경 표준화

학력

16.03.02 - 18.02.08	한국영상대학교 영상정보부사관과
	• 졸업

교육

25.11.20 - 26.06.19	코드잇 스프린트 부트캠프 AI Engineer 수료
	• 원리 이해 기반의 파이프라인 최적화: 단순 API 사용에 그치지 않고, 텍스트 청킹, 의미론적 검색, 비동기 처리의 원리를 딥다이브하여 실제 서비스 환경의 병목을 해결하는 E2E 아키텍처 설계 역량을 체득했습니다. • 가설-지표-평가 중심의 실험 체화: 하이퍼파라미터와 프롬프트를 수십 번 튜닝하며, 모델의 지연 시간과 정확도 간의 기술적 트레이드오프를 데이터로 분석해 최적의 스위트스팟을 도출하는 감각을 길렀습니다. • RCA(근본 원인 분석) 기반 트러블슈팅: 군 팀장 시절 체득한 리스크 통제 역량을 개발에 적용, 에러 발생 시 직관이 아닌 추적 로그와 지표를 바탕으로 원인을 규명하고 데이터 기반으로 팀의 기술적 의사결정을 이끌었습니다.

자격증

16.09.01	초경량비행장치 조종자 한국교통안전공단
----------	-------------------------